

TRABAJO PRÁCTICO Nº 1

Un primer encuentro con la EPH

Taller de Programación – Grupo 7

Integrantes: Antony Araujo – Erick Huamanchumo

Repositorio público de GitHub:

https://github.com/ErickHuamanchumo/Taller_Programacion_UBA_2026/tree/main/TP1

Objetivo y fuentes

El trabajo compara los microdatos individuales de la Encuesta Permanente de Hogares (EPH) correspondientes al cuarto trimestre de 2024 y 2025. Se armonizan 20 variables sustantivas y cinco identificadores, se limpian códigos de no respuesta, se actualizan los ingresos de 2024 a peso de diciembre de 2025, y se estudia la informalidad laboral mediante la definición “lower-tier informal wage employees” asignada a nuestro grupo.

La EPH identifica la informalidad asalariada a partir de la ausencia de aportes o descuentos jubilatorios realizados por el empleador. La definición de Maurizio y Monsalvo (2021) clasifica como lower-tier a los asalariados informales que trabajan en unidades de hasta cinco personas. Para el servicio doméstico se considera el sector hogares como unidad de baja escala.

Selección y armonización de variables

Variables de interés: CH04, CH06, CH07, CH08, NIVEL_ED, ESTADO, CAT_OCUP, EMPLEO, SECTOR, PP04C, PP04D_COD, P21, P47T, PP07H, PP3E_TOT, REGION, AGLOMERADO, PP04B_COD, PP04G y COMPONENTE.

Identificadores conservados: CODUSU, AN04, TRIMESTRE, NRO_HOGAR y PONDERA. Como auxiliares de clasificación se utilizan PP04C99 y PP04B1. Todos los campos, salvo CODUSU, se transformaron a formato numérico homogéneo en ambos años.

Universos de análisis

Año	Base total	ESTADO=0	Respondieron	Ocupados	Ocupados ponderados
2024	46 860	56	46 804	21 132	13 596 484
2025	43 703	65	43 638	19 698	13 503 383

En 2024, se identificaron 56 registros que no respondieron la pregunta sobre condición de actividad. Al aplicar el factor de expansión (PONDERA), estos casos representan aproximadamente 70 835 personas. Para 2025, el número de registros sin respuesta fue de 65, equivalentes 62 868 personas. Los casos con información faltante se agruparon en la base denominada norespondieron, mientras que los registros con respuesta se almacenaron en respondieron. Posteriormente, dentro de este último grupo, se seleccionaron únicamente los casos con ESTADO = 1, correspondientes a la población ocupada.


1. Limpieza, variables binarias e ingresos reales

Se interpretaron como faltantes los códigos explícitos de “Ns/Nr” del diccionario. 9 en CH07, CH08, NIVEL_ED, CAT_OCUP, EMPLEO y SECTOR; 99 en PP04C; 999 en PP3E_TOT; y 0/9 en PP07H cuando la pregunta no correspondía. En P21 y P47T los valores negativos —principalmente -9— se sustituyeron por NaN, porque representan no respuesta y no ingresos económicamente posibles. Los ceros se conservaron, ya que pueden indicar ausencia efectiva de ingreso. También se controló el rango de edad y se armonizaron los códigos de ocupación y actividad económica.

Se crearon las dicotómicas mujer, casado_unido, educacion_superior, ocupado, asalariado y sin_descuento_jubilatorio. Los nombres expresan directamente el evento codificado con 1, evitando etiquetas ambiguas en gráficos y regresiones.

Para comparar montos nominales se multiplicaron P21 y P47T de 2024 por 1,315. El factor corresponde a la variación interanual del IPC nacional de diciembre de 2025 (31,5%). Por lo tanto, todas las cifras de ingreso del análisis están expresadas en pesos de diciembre de 2025.


Figura 1: Porcentaje de faltantes de variables seleccionadas



La figura 1 evidencia que las variables demográficas presentan muy pocos datos faltantes. Entre los ocupados, las variables laborales se encuentran prácticamente completas, mientras que los mayores niveles de no respuesta corresponden a las variables de ingresos (P21 y P47T) y a PP07H, esta última debido a que solo aplica a trabajadores asalariados. En general, el patrón de datos faltantes se mantiene estable entre 2024 y 2025.

2. Primer análisis exploratorio

Figura 2: Correlaciones de Pearson calculadas con observaciones disponibles por par de variables



Las matrices de correlación presentan una alta similitud entre ambos años, con diferencias muy reducidas. La relación más alta y estable se da en el par de variables de P21-P47T (0,85 en 2024 y 0,86 en 2025), lo cual es esperable porque el ingreso de la ocupación principal integra el ingreso total. ESTADO y CAT_OCUP muestran una correlación cercana a -0,92 debido a la codificación y al universo de aplicación de la categoría ocupacional. También aparecen asociaciones moderadas entre edad y P47T, y entre edad y estado civil. En general, la estructura de correlaciones se mantiene estable entre 2024 y 2025, aunque los resultados que involucren variables categóricas deben interpretarse con cautela debido a la influencia de sus códigos numéricos.

Estadística descriptiva de variables seleccionadas

Variable	Año	N	Promedio	Desv. est.	p1	p50	p99	Máximo
CH06	2024	46 498	37,0	22,1	2,0	35,0	85,0	103,0
CH06	2025	43 391	37,8	22,2	2,0	36,0	86,0	101,0
P21	2024	42 526	\$ 326 977	\$ 631 796	\$ 0	\$ 0	\$ 2 630 000	\$ 13 150 000
P21	2025	39 724	\$ 364 445	\$ 727 928	\$ 0	\$ 0	\$ 3 000 000	\$ 30 000 000
P47T	2024	40 898	\$ 491 292	\$ 724 542	\$ 0	\$ 315 600	\$ 3 287 500	\$ 21 697 500
P47T	2025	38 084	\$ 544 200	\$ 843 555	\$ 0	\$ 350 000	\$ 3 500 000	\$ 30 000 000
PP3E_TOT	2024	21 088	35,9	16,3	0,0	40,0	84,0	154,0
PP3E_TOT	2025	19 655	35,9	16,4	0,0	40,0	84,0	168,0


La tabla completa se incluye en el Apéndice A y en los archivos CSV. Los ingresos presentan fuerte asimetría positiva ya que la media supera a la mediana y los máximos se ubican muy por encima del p99. En consecuencia, para describir el centro de la distribución conviene complementar el promedio con la mediana y los percentiles.

3. Informalidad laboral lower-tier

La clasificación se realizó dentro de ocupados asalariados (ESTADO=1 y CAT_OCUP=3). Se definió formal asalariado cuando PP07H=1, es decir, cuando existe descuento jubilatorio. **Se definió informal lower-tier cuando PP07H=2 y el establecimiento tiene hasta cinco personas (PP04C entre 1 y 5, o PP04C99=1).** El servicio doméstico (PP04B1=1 o SECTOR=3) se incorporó como unidad de baja escala. Los asalariados sin descuento en establecimientos de más de cinco personas se clasificaron como upper-tier y no se mezclaron con los formales.

Año	Grupo	Formal	Informal lower-tier	n clasificado	Población expandida
2024	Total	76,4%	23,6%	12 968	8 217 688
2024	Mujeres	72,7%	27,3%	6 205	3 877 167
2024	Hombres	79,8%	20,2%	6 763	4 340 521
2025	Total	75,7%	24,3%	11 768	8 125 459
2025	Mujeres	70,6%	29,4%	5 734	3 862 064
2025	Hombres	80,3%	19,7%	6 034	4 263 395


Figura 3: Porcentajes ponderados dentro del universo formal asalariado + informal lower-tier.



La incidencia lower-tier aumentó 0,7 puntos porcentuales al pasar de 23,6% en 2024 a 24,3% en 2025. La diferencia por sexo es marcada ya que las mujeres reportan las mayores tasas. Entre mujeres pasa de 27,3% a 29,4%, mientras que entre hombres disminuye levemente de 20,2% a 19,7%. En 2025 la brecha mujeres-hombres alcanza 9,7 puntos porcentuales. Por tanto, el deterioro agregado se concentra en las mujeres. Como control, al usar el total de asalariados, en 2025 se obtiene 63,7% formal, 20,4% lower-tier, 12,6% upper-tier y 3,3% no clasificable; esta descomposición completa se muestra en el Apéndice B.

4. Distribución de ingresos y conclusiones

Figura 4: Distribuciones de ingresos de asalariados formales vs lower-tier informales



Las distribuciones son asimétricas a la derecha, pero las de los formales se encuentran claramente desplazadas hacia ingresos mayores. En 2025 la mediana ponderada de P21 es \$ 1 000 000 para formales y \$ 400 000 para lower-tier; en P47T las medianas son \$ 1 200 000 y \$ 560 000, respectivamente. P21 mide solo la ocupación principal y omite otros trabajos e ingresos no laborales; P47T incorpora esos componentes, pero ambas variables tienen no respuesta, valores cero, redondeo y extremos. El recorte visual al p99 no elimina observaciones del cálculo de tablas, solo mejora la legibilidad del gráfico.

La estructura de faltantes y correlaciones es estable entre años. Sin embargo, la informalidad lower-tier registra un aumento moderado, explicado por una mayor incidencia entre las mujeres. Las brechas de ingreso son amplias y persistentes: los trabajadores lower-tier se concentran en la parte baja de las distribuciones tanto de P21 como de P47T.

Uso de IA y tiempo dedicado

El uso de la IA fue de gran ayuda durante el desarrollo de la programación, especialmente para resolver dudas relacionadas con la sintaxis, la depuración de errores y la elaboración de códigos para el procesamiento y análisis de datos. Resultó particularmente útil en tareas repetitivas, como la limpieza de bases de datos, el tratamiento de valores faltantes y la generación de gráficos y tablas descriptivas. Fue menos efectiva en decisiones conceptuales que requieren leer el diccionario y justificar el universo, por lo que las sugerencias debieron contrastarse con la documentación oficial.

Tiempo total dedicado por el grupo: 12 horas.

Referencias:

- INDEC (2026), Diseño de registros EPH 4T2025, EPH 4T2024, IPC diciembre de 2025.
- Maurizio, R. y Monsalvo, A. P. (2021), Informality, labour transitions, and the livelihoods of workers in Latin America, WIDER Working Paper 2021/19.
- Schwabish, J. A. (2014), An economist's guide to visualizing data.

APÉNDICE A. Estadística descriptiva completa

Las tablas se calculan sobre respondieron. Los códigos categóricos se resumen numéricamente para cumplir la consigna, aunque sus promedios no siempre poseen una interpretación económica directa. P21 y P47T están en pesos de diciembre de 2025.

Año 2024

Variable	n	media	sd	min	p1	p25	p50	p75	p99	max
CH04	46 804	1.5	0.5	1.0	1.0	1.0	2.0	2.0	2.0	2.0
CH06	46 498	37.0	22.1	1.0	2.0	19.0	35.0	54.0	85.0	103.0
CH07	46 804	3.5	1.7	1.0	1.0	2.0	5.0	5.0	5.0	5.0
CH08	46 762	2.1	1.9	1.0	1.0	1.0	1.0	4.0	12.0	123.0
NIVEL_ED	46 804	3.8	1.8	1.0	1.0	3.0	4.0	5.0	7.0	7.0
ESTADO	46 804	2.2	1.1	1.0	1.0	1.0	3.0	3.0	4.0	4.0
CAT_OCUP	46 801	1.3	1.4	0.0	0.0	0.0	0.0	3.0	3.0	4.0
EMPLEO	21 116	1.4	0.5	1.0	1.0	1.0	1.0	2.0	2.0	2.0
SECTOR	20 275	1.4	0.6	1.0	1.0	1.0	1.0	2.0	3.0	3.0
PP04C	18 423	5.0	3.8	0.0	0.0	1.0	5.0	8.0	12.0	12.0
PP04D_COD	21 119	44 969.7	23 003.8	1.0	5 001.0	30 313.0	41 332.0	58 113.0	90 292.4	99998.0
P21	42 526	326 976.9	631 795.6	0.0	0.0	0.0	0.0	499 700.0	2630000.0	13150000.0
P47T	40 898	491 291.5	724 542.5	0.0	0.0	0.0	315 600.0	715 360.0	3287500.0	21697500.0
PP07H	15 292	1.4	0.5	1.0	1.0	1.0	1.0	2.0	2.0	2.0
PP3E_TOT	21 088	35.9	16.3	0.0	0.0	25.0	40.0	48.0	84.0	154.0
REGION	46 804	35.4	15.2	1.0	1.0	40.0	42.0	43.0	44.0	44.0
AGLOMERADO	46 804	23.3	17.6	2.0	2.0	12.0	22.0	32.0	93.0	93.0
PP04B_COD	21 132	6 300.5	2 500.5	20.0	104.0	4 803.0	6 000.0	8 501.0	9 700.0	9 999.0
PP04G	19 723	9.6	2.3	2.0	3.0	8.0	11.0	11.0	12.0	13.0
COMPONENTE	46 804	2.4	1.6	1.0	1.0	1.0	2.0	3.0	8.0	56.0

Año 2025

Variable	n	media	sd	min	p1	p25	p50	p75	p99	max
CH04	43 638	1.5	0.5	1.0	1.0	1.0	2.0	2.0	2.0	2.0
CH06	43 391	37.8	22.2	1.0	2.0	19.0	36.0	55.0	86.0	101.0
CH07	43 637	3.5	1.6	1.0	1.0	2.0	5.0	5.0	5.0	5.0
CH08	43 535	2.1	1.7	1.0	1.0	1.0	1.0	4.0	12.0	23.0
NIVEL_ED	43 638	3.8	1.7	1.0	1.0	3.0	4.0	5.0	7.0	7.0
ESTADO	43 638	2.2	1.1	1.0	1.0	1.0	3.0	3.0	4.0	4.0
CAT_OCUP	43 635	1.3	1.4	0.0	0.0	0.0	0.0	3.0	3.0	4.0
EMPLEO	19 688	1.4	0.5	1.0	1.0	1.0	1.0	2.0	2.0	2.0
SECTOR	18 948	1.4	0.6	1.0	1.0	1.0	1.0	2.0	3.0	3.0
PP04C	17 004	4.8	3.8	0.0	0.0	1.0	4.0	8.0	12.0	12.0
PP04D_COD	19 681	44912.9	22976.4	1.0	5002.0	30203.0	41332.0	57314.0	90146.0	99998.0
P21	39 724	364445.4	727927.6	0.0	0.0	0.0	0.0	600000.0	3000000.0	30000000.0
P47T	38 084	544200.4	843555.1	0.0	0.0	0.0	350000.0	800000.0	3500000.0	30000000.0
PP07H	13 943	1.4	0.5	1.0	1.0	1.0	1.0	2.0	2.0	2.0
PP3E_TOT	19 655	35.9	16.4	0.0	0.0	25.0	40.0	48.0	84.0	168.0
REGION	43 638	35.4	15.2	1.0	1.0	40.0	42.0	43.0	44.0	44.0
AGLOMERADO	43 638	23.1	17.3	2.0	2.0	10.0	22.0	32.0	93.0	93.0
PP04B_COD	19 698	6295.5	2502.8	19.0	104.0	4803.0	5602.0	8501.0	9700.0	9999.0
PP04G	18 356	9.6	2.4	2.0	3.0	8.0	11.0	11.0	12.0	13.0
COMPONENTE	43 638	2.4	1.5	1.0	1.0	1.0	2.0	3.0	7.0	18.0

APÉNDICE B. Descomposición completa de asalariados

Año	Grupo	Formal	Lower-tier	Upper-tier	No clasificable	n
2024	Total	63,9%	19,7%	12,8%	3,6%	15 292
2024	Mujeres	61,6%	23,1%	12,3%	3,0%	7 184
2024	Hombres	65,8%	16,7%	13,3%	4,2%	8 108
2025	Total	63,7%	20,4%	12,6%	3,3%	13 943
2025	Mujeres	61,6%	25,7%	10,8%	2,0%	6 580
2025	Hombres	65,5%	16,0%	14,1%	4,4%	7 363

Nota: los porcentajes se calculan sobre todos los asalariados ocupados y suman 100% dentro de cada año y grupo. La tabla principal del informe se concentra en la comparación solicitada entre formal asalariado e informal lower-tier, excluyendo upper-tier y no clasificables del denominador.

APÉNDICE C. Prompts de IA utilizados

Herramienta/LLM: ChatGPT – GPT-5.6 Thinking mediante Copilot.
Prompt utilizados:

- “Quiero que te pongas en modo especialista de base de datos en colab y me ayudes con mi trabajo de programación sobre la EPH.”*
- “Analiza integralmente la consigna contenida en Programacion_UBA_TP1.docx y construye un plan de trabajo ordenado para resolverla utilizando las bases usu_individual_T424.xlsx y usu_individual_T425.xlsx, correspondientes al cuarto trimestre de 2024 y 2025.”*
- “Utilizando las bases respondieron y ocupados, realiza el análisis exploratorio solicitado para 2024T4 y 2025T4.”*
- “Para la Parte III, considera que pertenecemos al grupo 7 y que nos corresponde construir la categoría ‘Lower-tier informal wage employees’, siguiendo la definición de Maurizio y Monsalvo (2021)”.*

APÉNDICE D. Decisiones reproducibles

Decisión	Implementación
Ingresos negativos	Se convierten a NaN; los ceros se conservan.
Actualización monetaria	P21 y P47T de 2024 × 1,315.
No respuesta ESTADO	ESTADO=0 se guarda en norespondieron.
Ocupados	ESTADO=1 dentro de respondieron.
Formal asalariado	CAT_OCUP=3 y PP07H=1.
Lower-tier informal	CAT_OCUP=3, PP07H=2 y unidad de hasta 5 personas; se incluye servicio doméstico/sector hogares.
Ponderación	Pondera en tasas, histogramas y resúmenes de ingreso.
Gráficos de ingreso	Solo ingresos positivos; eje hasta p99, sin eliminar extremos de las tablas.