

UNIVERSIDAD DE BUENOS AIRES

TRABAJO PRÁCTICO N.º 4

Taller de Programación – Grupo 7
Integrantes: Antony Araujo – Erick Huamanchumo

Repositorio público de GitHub:

https://github.com/ErickHuamanchumo/Taller_Programacion_UBA_2026/tree/main/TP4

Objetivo y estrategia empírica

- **Objetivo.** Predecir la probabilidad de que un trabajador asalariado pertenezca al segmento informal lower-tier en 2025, comparando regresión logística sin penalización, LASSO, Ridge y un árbol CART podado.
- **Definición.** Se considera lower-tier al asalariado sin descuento jubilatorio que trabaja en un establecimiento de hasta cinco personas. Los casos no clasificables se excluyen de la variable objetivo.
- **Muestra longitudinal.** Se identificaron 3,013 personas presentes en 2024 y 2025 mediante CODUSU, NRO_HOGAR y COMPONENTE. En 2025, 413 trabajadores (13.7%) son lower-tier; en 2024 la proporción dentro de esta misma muestra fue 14.2%.

Variables y evaluación

La matriz X contiene 28 predictores: características personales, educativas, laborales, del hogar, variables regionales y el rezago de informalidad de 2024. Para evitar fuga de información se excluyen variables que forman parte directa de la definición de lower-tier. Las variables categóricas se transforman en dummies y los predictores se estandarizan en los modelos regularizados. La comparación predictiva se realiza con predicciones out-of-fold de 5 folds, de modo que cada observación es evaluada por un modelo que no la utilizó en su estimación.

La grilla de regularización es $\lambda = 10^n$, con n entre -5 y 5. En LogisticRegression se utiliza $C = 1/\lambda$. Para CART, el costo de complejidad ccp_alpha se selecciona por validación cruzada de 5 folds.

A. Regresión logística con regularización: Ridge y LASSO

A.1. Trayectoria de coeficientes




Figura 1. Trayectoria de los coeficientes para LASSO y Ridge según λ .

La figura muestra el efecto esperado de la regularización: cuando λ aumenta, los coeficientes se acercan a cero. La diferencia central es que LASSO puede llevar algunos coeficientes exactamente a cero, mientras que Ridge los reduce sin eliminarlos. Por ello, LASSO combina regularización con selección de variables.

A.2. Penalidad óptima por Cross-Validation




Figura 2. Distribución del error de clasificación en 5-fold CV para cada λ .

Resultado: La validación cruzada seleccionó $\lambda = 10$ para LASSO y $\lambda = 10$ para Ridge. En ambos casos la penalización elegida reduce la complejidad sin deteriorar de forma relevante el desempeño de clasificación.

A.3. Comparación de coeficientes

Variable	Sin penal.	LASSO	Ridge
informal_2024	0.956	0.938	0.902
tiene_cobertura_medica	-0.798	-0.733	-0.723
P21	-1.057	-0.591	-0.472
CH06	-1.832	-0.034	-0.345
educ	-0.152	-0.082	-0.131
P47T	0.221	0.000	-0.068

La comparación de coeficientes muestra que LASSO y Ridge reducen la magnitud de los coeficientes respecto al modelo sin penalización, lo que ayuda a evitar que el modelo dependa excesivamente de ciertas variables. La informalidad en 2024 mantiene un coeficiente positivo y elevado en los tres modelos, por lo que sigue siendo uno de los principales factores asociados con la informalidad en 2025. En cambio, tener cobertura médica y un mayor ingreso de la ocupación principal (P21) presentan coeficientes negativos, lo que indica una menor probabilidad de pertenecer al grupo informal lower-tier. La edad (CH06) también reduce notablemente su coeficiente con la regularización, especialmente bajo LASSO. Finalmente, LASSO lleva el coeficiente de P47T a cero, lo que sugiere que esta variable aporta poca información adicional una vez consideradas las demás características. En general, la regularización permite obtener un modelo más estable y, en el caso de LASSO, también más simple al eliminar variables poco relevantes.

B. Árboles de decisión

B.1. Selección del árbol podado




Figura 3. Error de clasificación según ccp_alpha .

Resultado: La figura 3 muestra que el error de clasificación disminuye a medida que se poda el árbol hasta alcanzar un punto mínimo, correspondiente aproximadamente a un ccp_alpha de 0.0018. A partir de ese valor, una poda más intensa vuelve a incrementar el error, lo que indica que el árbol empieza a simplificarse demasiado y pierde capacidad predictiva. Por ello, se selecciona este valor como el nivel óptimo de poda, ya que logra un buen equilibrio entre precisión y simplicidad. El árbol final tiene profundidad 4 y 6 hojas, por lo que resulta mucho más sencillo de comunicar que un árbol sin podar.

B.2. Árbol final e importancia de predictores




Figura 4. Panel A: árbol CART podado por validación cruzada.




Figura 5. Panel B: importancia de predictores.

El árbol utiliza principalmente cuatro predictores: informal_2024 (80.3%), tiene_cobertura_medica (14.9%), horas_totales_ocupado (3.0%), P21 (1.8%). La primera división se realiza con informal_2024, confirmando que la condición del año anterior es la señal más fuerte. La cobertura médica ocupa el segundo lugar y las horas trabajadas y P21 aparecen en ramas posteriores. No existe una coincidencia perfecta con LASSO: ambos métodos simplifican el problema de manera distinta, porque LASSO actúa sobre asociaciones lineales mientras CART busca umbrales e interacciones.

C. Comparación entre métodos

Modelo	Accuracy	1-Acc.	Precisión	Sensib.	F1	ROC-AUC
Logit sin penalidad	0.922	0.078	0.757	0.632	0.689	0.943
LASSO	0.923	0.077	0.792	0.591	0.677	0.942
Ridge	0.923	0.077	0.776	0.620	0.689	0.942
CART	0.926	0.074	0.745	0.695	0.719	0.910




Figura 6. Curvas ROC de los cuatro modelos.




Figura 7. Matrices de confusión con umbral 0,5.

Los resultados muestran que no hay un ganador absoluto. CART obtiene el menor error total ($1 - \text{accuracy} = 7.4\%$), la mayor sensibilidad (69.5%) y el mejor F1 (71.9%), por lo que detecta una mayor proporción de trabajadores lower-tier. LASSO, en cambio, alcanza la mayor precisión (79.2%), lo que significa que cuando clasifica a una persona como vulnerable se equivoca menos. Los tres modelos logísticos presentan ROC-AUC cercanos a 0.94, superiores al 0.91 de CART, de modo que ordenan mejor el riesgo en términos globales.

Es preciso mencionar que en el trade-off entre comunicación y performance, CART es especialmente transparente porque se traduce en pocas reglas de decisión. Sin embargo, el método no lineal no domina en todas las métricas: su ventaja aparece principalmente en sensibilidad y F1 con umbral 0.5, mientras que los modelos logísticos conservan una mejor discriminación global medida por ROC-AUC.

C.2. Evaluación regional y recomendación de política pública

Para el análisis territorial se seleccionó la región Noroeste (NOA), código 40, porque concentra el mayor número de informales lower-tier en la muestra longitudinal: 145 casos sobre 819 trabajadores (17.7%).

Modelo	Accuracy	Precisión	Sensib.	F1	ROC-AUC
Logit sin penalidad	0.924	0.843	0.703	0.767	0.950
LASSO	0.927	0.846	0.717	0.776	0.951
Ridge	0.928	0.852	0.717	0.779	0.950
CART	0.927	0.781	0.814	0.797	0.947

En el NOA, CART destaca por sensibilidad (81.4%) y F1 (79.7%), mientras Ridge presenta la mayor precisión (85.2%). Esto evidencia que un modelo con buen desempeño agregado puede comportarse de forma distinta en una región particular. Por tanto, la implementación de una política pública debería revisar el desempeño territorial y no basarse únicamente en un promedio nacional.

Recomendación

Si la Secretaría de Trabajo prioriza no dejar fuera a trabajadores precarizados, CART es atractivo con el umbral 0.5 porque reduce los falsos negativos. Si los recursos son muy escasos y se desea minimizar asignaciones a personas no objetivo, LASSO o Ridge resultan más convenientes por su mayor precisión. Una estrategia práctica sería utilizar las probabilidades de LASSO/Ridge como ranking de riesgo, seleccionar beneficiarios hasta agotar el presupuesto y aplicar una segunda verificación administrativa. La elección final del umbral debe reflejar explícitamente el costo relativo de falsos positivos y falsos negativos.

D. Uso de Inteligencia Artificial y reflexión

La IA fue útil para traducir la consigna en una secuencia reproducible, revisar la relación entre λ y C, organizar la validación cruzada, automatizar tablas y gráficos y explicar las diferencias entre LASSO, Ridge y CART. Su aporte fue menor en las decisiones que requieren criterio sustantivo tales como: evitar fuga de información, decidir qué error es más costoso y recomendar un modelo para política pública. Estas decisiones fueron revisadas a partir de la definición de informalidad, la estructura de la base y las métricas efectivamente obtenidas y analizadas.

Conclusión

La regularización permite simplificar la regresión logística sin perder capacidad predictiva: LASSO elimina 10 predictores y Ridge reduce todos sin llevarlos a cero. CART logra el mejor F1 y la mayor sensibilidad, pero los modelos logísticos mantienen mejor ROC-AUC. En conjunto, la informalidad previa y la cobertura médica son los predictores más consistentes. La elección del modelo depende del objetivo de la política: detectar más vulnerables o focalizar con mayor precisión.

Referencias

INDEC. Encuesta Permanente de Hogares (EPH), bases individuales 4T 2024 y 4T 2025; diseño de registros.
Maurizio, R. y Monsalvo, A. P. (2021). Informality, labour transitions, and the livelihoods of workers in Latin America. UNU-WIDER Working Paper 2021/19.

APÉNDICES

Apéndice A. Tabla completa de coeficientes

Variable	Logit sin penal.	LASSO	Ridge
es_mujer	0.0551	0.0000	0.0294
vive_en_pareja	-0.0735	-0.0588	-0.0895
tiene_cobertura_medica	-0.7979	-0.7334	-0.7235
asiste_actualmente	-0.0166	0.0000	0.0123
secundario_completo_o_mas	0.0112	0.0000	-0.0127
CH06	-1.8321	-0.0338	-0.3446
edad2	1.7835	0.0000	0.3090
educ	-0.1524	-0.0823	-0.1311
nhogar	-0.0993	-0.0148	-0.0814
es_subocupado	0.0344	0.0332	0.0426
horas_totales_ocupado	-0.1198	-0.0365	-0.1152
P21	-1.0573	-0.5908	-0.4722
P47T	0.2213	0.0000	-0.0681
informal_2024	0.9556	0.9379	0.9023
REGION_40	-0.3630	-0.0884	-0.2237
REGION_41	-0.1426	0.0000	-0.0698
REGION_42	-0.3101	-0.0798	-0.1965
REGION_43	-0.1696	0.0244	-0.0659
REGION_44	-0.2347	0.0000	-0.1404
MAS_500_S	0.0357	0.0585	0.0565
CH03_2	0.1327	0.0000	0.0914
CH03_3	0.2529	0.1902	0.2448
CH03_4	0.1369	0.0451	0.1136
CH03_5	0.0047	0.0000	0.0264
CH03_6	-0.1640	0.0000	-0.0193
CH03_8	0.0940	0.0521	0.0875
CH03_9	0.0702	0.0179	0.0601
CH03_10	-0.3859	-0.0414	-0.1148

El modelo LASSO parte de 28 predictores en total. Sin embargo, con el valor óptimo de regularización seleccionado, LASSO lleva 10 coeficientes a cero. Por tanto, el modelo final conserva 18 predictores con coeficiente distinto de cero.

Variables llevadas a cero por LASSO: es_mujer, asiste_actualmente, secundario_completo_o_mas, edad2, P47T, REGION_41, REGION_44, CH03_2, CH03_5, CH03_6.

Apéndice B. Regularización y evaluación complementaria




Figura A1. Proporción de variables ignoradas por LASSO según λ .

A medida que λ aumenta, la proporción de coeficientes exactamente iguales a cero crece de forma marcada. El resultado ilustra la capacidad de LASSO para construir una especificación más parsimoniosa.

Cuadro B1. Matrices de confusión en valores absolutos

Modelo	TN	FP	FN	TP
Logit sin penalidad	2516	84	152	261
LASSO	2536	64	169	244
Ridge	2526	74	157	256
CART	2502	98	126	287

Cuadro B2. Desempeño en la región Noroeste

Modelo	N	Informales	Accuracy	Precisión	Sensib.	F1	ROC-AUC
Logit sin penalidad	819	145	0.9243	0.8430	0.7034	0.7669	0.9504
LASSO	819	145	0.9267	0.8455	0.7172	0.7761	0.9506
Ridge	819	145	0.9280	0.8525	0.7172	0.7790	0.9505
CART	819	145	0.9267	0.7815	0.8138	0.7973	0.9469

Apéndice C. Uso de IA, prompts y trazabilidad

Herramientas utilizadas: ChatGPT y Copilot.

1. Genera el código en Python usando scikit-learn para entrenar modelos de Regresión Logística con penalidad Ridge y LASSO. Necesito variar el parámetro de penalidad en una grilla de 10^{-5} a 10^5 y graficar en dos paneles cómo cambian los coeficientes a medida que cambia la regularización.
2. ¿Cómo puedo usar la función LogisticRegressionCV con 5 particiones para encontrar el hiperparámetro de penalidad óptimo? Además, muéstrame cómo hacer box-plots del error de predicción para cada valor evaluado en la grilla.
3. Explicame de forma sencilla la diferencia teórica entre la penalidad LASSO y Ridge. ¿Por qué se dice que LASSO funciona como un selector de variables y reduce algunos coeficientes exactamente a cero mientras que Ridge no?
4. Escribe el código para ajustar un árbol de decisión de clasificación en Python, buscando el mejor parámetro de costo de complejidad mediante validación cruzada de 5 particiones. Incluye el código para graficar el error de clasificación vs los valores de `ccp_alpha`.
5. ¿Cómo extraigo y hago un gráfico de la importancia de los predictores de un árbol de decisión ya entrenado en scikit-learn? ¿Tiene sentido teórico comparar las variables que el árbol considera menos importantes con las que LASSO eliminó previamente?
6. Desde el punto de vista de las políticas públicas y la asignación de recursos escasos, ¿cómo explico el trade-off entre la facilidad de comunicación de un árbol de decisión y el poder predictivo de un modelo logístico? Ayúdame a justificarlo usando métricas como la curva ROC y $(1 - \text{accuracy})$.

Tiempo total dedicado

El tiempo total aproximado dedicado por el grupo fue de 12 horas.